

# Técnicas de Validação e Ajuste de Modelos

Leonardo Raiz

August 4, 2025

$$D = D_{\text{train}} \cup D_{\text{test}}, \quad D_{\text{train}} \cap D_{\text{test}} = \emptyset$$
$$\text{Acurácia} = \frac{1}{|D_{\text{test}}|} \sum_{x_i \in D_{\text{test}}} \mathbb{I}(f(x_i) = y_i)$$

*Divide uma única vez o conjunto de dados em treino e teste. Simples, mas sensível à divisão.*

# K-Fold Cross-Validation

$$\text{Acurácia Média} = \frac{1}{K} \sum_{k=1}^K \left( \frac{1}{|D^{(k)}|} \sum_{x_i \in D^{(k)}} \mathbb{I}(f^{(k)}(x_i) = y_i) \right)$$

*Os dados são divididos em  $K$  partes. Cada parte é usada uma vez como teste.*

# Leave-One-Out (LOO)

$$\text{Acurácia LOO} = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(f^{(-i)}(x_i) = y_i)$$

*Cada exemplo é usado como teste uma vez. Muito preciso, mas lento em grandes conjuntos.*

# Stratified K-Fold

$$P(y = 1 \mid D^{(k)}) \approx P(y = 1 \mid D), \quad \forall k$$

*Igual ao K-Fold, mas preserva a proporção das classes em cada fold.*

# ShuffleSplit (Subamostragem)

$$\text{Acurácia Média} = \frac{1}{R} \sum_{r=1}^R \frac{1}{|D_{\text{test}}^{(r)}|} \sum_{x_i \in D_{\text{test}}^{(r)}} \mathbb{I}(f^{(r)}(x_i) = y_i)$$

*Faz várias divisões aleatórias entre treino e teste. Estável e flexível.*

# Sub Ajuste (Underfitting)

$$f(x) = \text{sign}(w^\top x + b)$$

*Modelo simples demais para aprender os padrões dos dados. Acurácia baixa no treino e teste.*

# Super Ajuste (Overfitting)

$$f(x) = \text{sign}(w_0 + w_1x + w_2x^2 + \cdots + w_nx^n)$$

*Modelo complexo demais, aprende até os ruídos. Acurácia alta no treino, baixa no teste.*



$$f(x) = \text{sign}(w^\top x + b)$$
$$\min_w \frac{1}{n} \sum_{i=1}^n \mathcal{L}(f(x_i), y_i) + \lambda \|w\|^2$$

*Modelo com complexidade equilibrada, generaliza bem. Boa acurácia no treino e teste.*